Universitas Mercatorum

Università telematica delle Camere di Commercio Italiane

FACOLTÀ DI SCIENZE TECNOLOGICHE E DELL'INNOVAZIONE

CORSO DI LAUREA IN STATISTICA E BIG DATA

Prova Finale in

PROGRAMMAZIONE PER LA STATISTICA E I BIG DATA

Progettazione e valutazione di strategie di trading quantitativo basate su modelli predittivi

RELATORE
Chiar.mo
Prof. Agostinelli Simone

CANDIDATO
CIARAMELLA ANGELO
MATR. 0412300192

Anno Accademico 2025/2026

INDICE

1. Fondamenti di trading quantitativo……..……..…pag.3
   1.1. Introduzione…….....pag.3
   1.2. Obiettivi della tesi…….....pag.3
   1.3. Confronto con i lavori scientifici esistenti……..…….pag.4
   1.4. Trading quantitativo e trading algoritmico: definizioni e caratteristiche…….....pag.5
   1.5. Architettura di un sistema di trading……..……..…..pag.6
   1.6. Metodologia scientifica nello sviluppo di strategie…….....pag.8
   1.7. Struttura dell'elaborato…….…pag.9
2. Modelli predittivi……..……..….pag.10
   2.1. Introduzione ai modelli predittivi……..……..….pag.10
   2.2. Modelli Econometrici tradizionali……..pag.10
      2.2.1. Modelli AR, MA e ARIMA…….…….pag.10
      2.2.2. Modello ARFIMA…….……...pag.10
      2.2.3. Modelli GARCH…….…….pag.10
   2.3. Modelli ML/DL…….….……pag.11
      2.3.1. Modelli di Machine Learning……..…….....pag.11
      2.3.2. Modelli di Deep Learning……pag.11
   2.4. Modelli ibridi……..……pag.11
   2.5. Tecniche di validazione per Serie Temporali……..……pag.12
3. Framework sperimentale……...……pag.13
   3.1. Obiettivi del framework sperimentale……pag.13
   3.2. Dati e universo di riferimento…….…pag.13
      3.2.1. Scelta dell'asset e orizzonte temporale……pag.13
      3.2.2. Fonti di dati……..……pag.13
      3.2.3. Struttura della serie e variabili di base…….……...…….pag.13
   3.3. Preprocessing e data cleaning……...…….……pag.13
   3.4. Feature engineering……...……pag.14
   3.5. Definizione dei target e configurazioni dei modelli……...…...……pag.14
      3.5.1. Target di classificazione direzionale……...……..…pag.14
      3.5.2. Modelli singoli……...…….……pag.15
      3.5.3. Modelli ibridi lineare-non lineare……...……pag.15
      3.5.4. Schema di validazione temporale……...……pag.15
   3.6. Costruzione delle strategie di trading…….…...……pag.16
      3.6.1. Segnale operativo……..….……..…pag.16
      3.6.2. Modellazione dei costi di transazione e volatilità…….….……..pag.16
      3.6.3. Metriche predittive e operative…….…….....pag.16
4. Risultati sperimentale……...…pag.18
   4.1. Preprocessing dei dati giornalieri……..….…pag.18
   4.2. Modelli……...…pag.18
      4.2.1. ARIMA/ARFIMA + Ensemble ML……pag.18
      4.2.2. ARIMA/ARFIMA + DL…….……pag.20
      4.2.3. Confronto…….…pag.21
      4.2.4. Interpretabilità dei modelli ibridi mediante SHAP……..pag.21

4.3. Rischio e costi…….…pag.23
4.3.1. Stima della volatilità condizionata e misure di rischio (GARCH)…….……..pag.23
4.3.2. Metriche di rischio delle strategie operative…….……pag.26
5. Conclusioni……pag.29
5.1. Sintesi dei risultati……..……..…pag.29
5.2. Contributi della tesi e considerazioni finali……..…pag.29

Bibliografia……..…pag.31

1 Fondamenti di trading quantitativo

1.1 Introduzione

Negli ultimi anni i mercati finanziari hanno assistito a una crescente diffusione di approcci quantitativi fondati sulla modellazione statistica e sulla previsione dei rendimenti [1]. L'elevata disponibilità di dati storici, l'aumento della potenza computazionale e lo sviluppo di algoritmi avanzati hanno reso possibile l'elaborazione di strategie sistematiche sempre più complesse [1]. In questo contesto, il trading quantitativo si è affermato come disciplina che integra analisi dei dati, modelli predittivi e tecniche statistiche per individuare pattern ricorrenti e inefficienze di mercato [1]. Esso si distingue per l'impiego esplicito di metodi matematici volti a formulare segnali operativi oggettivi, riducendo al minimo l'intervento discrezionale [1]. La presente tesi si inserisce in questo filone e si concentra sulla progettazione e valutazione di strategie di trading quantitativo, sviluppate tramite l'impiego di modelli predittivi, con l'obiettivo di studiare come differenti tecniche possano supportare la generazione di segnali di trading affidabili. Il trading algoritmico, inteso come automazione dell'esecuzione, costituisce un'estensione operativa del paradigma quantitativo [1]. Un'architettura algoritmica si distingue perché consiste nell'impiego di un sistema automatizzato che esegue operazioni di trading in modo predeterminato, seguendo un algoritmo e senza alcun intervento umano, così da ridurre l'intervento discrezionale, mitigando i bias psicologici e consentendo un monitoraggio costante dei mercati [1]. Parallelamente, l'integrazione di modelli Econometrici con tecniche di Machine Learning rappresenta un'evoluzione metodologica rilevante [5]. Il lavoro di Stempień e Ślepaczuk, ad esempio, sottolinea la complementarità tra approcci lineari, come ARIMA e ARFIMA (Autoregressive Integrated Moving Average e Autoregressive Fractionally Integrated Moving Average) e algoritmi non lineari come Support Vector Machine (SVM), XGBoost e Long Short-Term Memory (LSTM) [5]. La ricerca recente suggerisce inoltre come l'uso di tecniche avanzate ed ensemble possa migliorare la capacità predittiva e la profittabilità delle strategie [3]. Il paper di Krauss, Do e Huck mostra, nel contesto dello S&P 500[1], che l'unione dei modelli utilizzati ha portato vantaggi predittivi migliori rispetto all'utilizzo dei modelli singoli: "per il semplice ensemble ES1 […] troviamo rendimenti medi grezzi dello 0,45 percento al giorno prima dei costi di transazione"[2] [3], evidenziandone il potenziale nella generazione di segnali direzionali. Allo stesso tempo, Saifan et al. sottolineano che l'utilizzo di indicatori tecnici e sistemi ensemble consente di "identificare accuratamente patterns nelle azioni di mercato e di predire il futuro movimento di un'azione"[3] [4]. Tuttavia, la letteratura mette in luce anche limiti e insidie nell'applicazione diretta dei modelli ai mercati reali. Halls-Moore richiama l'attenzione sui rischi legati ai bias del backtesting [1][2]. Mentre il tema della robustezza fuori campione è affrontato da Krauss et al. tramite l'uso di finestre di test non sovrapposte e valutazioni su periodi multipli [3]. Alla luce di ciò, l'obiettivo dell'elaborato è proporre un approccio sperimentale originale che integri tecniche Econometriche e di Machine Learning in un framework coerente, valutando la capacità dei sistemi di generare segnali di trading efficaci su frequenze giornaliere e attraverso una validazione rigorosa. Questa impostazione è coerente con l'approccio scientifico, in cui la costruzione di un sistema è presentata come un processo iterativo basato su ipotesi, test e validazione [1].

1.2 Obiettivi della tesi

La presente tesi si propone di contribuire allo studio del trading quantitativo basato su modelli predittivi attraverso tre direttrici principali, tra loro complementari. Gli obiettivi individuati rispondono all'esigenza di valutare non solo la capacità teorica dei modelli di apprendere la dinamica dei rendimenti, ma anche la loro effettiva trasferibilità operativa all'interno di un framework di backtesting realistico e privo di bias.

---

[1] Indice azionario statunitense che misura la performance delle 500 maggiori società quotate negli USA

[2] "for the simple ensemble (ENS1) [...] we find average raw returns of 0.45 percent per day prior to transaction costs"

[3] "accurately identify stock market patterns and predict the future movement of a stock"

1) Sviluppare e valutare modelli predittivi ibridi

Il primo obiettivo consiste nella costruzione e nell'analisi di modelli predittivi che combinano una componente Econometrica lineare, rappresentata dai modelli ARIMA e ARFIMA, con una componente non lineare basata su algoritmi di Machine Learning (ML) e Deep Learning (DL), quali Logistic Regression, Random Forest, XGBoost e LSTM. A differenza di alcune impostazioni presenti in letteratura [5], questa tesi non utilizza i residui dei modelli Econometrici come input ai modelli non lineari; al contrario, sfrutta direttamente le previsioni ARIMA e ARFIMA come feature aggiuntive per i modelli ML e DL. Tale scelta mira a verificare se l'integrazione di segnali lineari e non lineari possa migliorare la capacità di predire la direzione del rendimento del giorno successivo rispetto ai modelli utilizzati singolarmente. L'obiettivo è comprendere se un approccio ibrido, pur rimanendo parsimonioso nella costruzione delle feature, possa fornire un vantaggio informativo in un contesto, come quello delle serie finanziarie crypto, caratterizzato da elevato rumore e bassa prevedibilità.

2) Valutare l'impatto della parsimonia delle feature e della stabilità dei modelli predittivi

Il secondo obiettivo consiste nell'esaminare come la semplicità del set di feature e la struttura dei modelli influenzino la stabilità e la robustezza delle previsioni giornaliere. Poiché i rendimenti di Bitcoin presentano un rapporto segnale–rumore estremamente ridotto [5], l'adozione di modelli parsimoniosi, basati esclusivamente su ritardi dei rendimenti e previsioni ARIMA/ARFIMA, costituisce un elemento centrale per evitare fenomeni di overfitting e per comprendere il contributo reale delle diverse componenti del modello. L'analisi mira a valutare:

- la capacità dei modelli lineari, ML e DL di generalizzare in un contesto di alta volatilità;
- la stabilità delle previsioni in regime out-of-sample;
- il ruolo effettivo della componente lineare nei modelli ibridi;
- il trade-off tra complessità del modello e robustezza operativa.

Questo obiettivo consente di chiarire in che misura sistemi complessi offrano un reale beneficio rispetto a configurazioni più semplici, e quali siano le condizioni in cui ciascun approccio risulta più efficace.

3) Progettare un framework di backtesting realistico e time-consistent

Il terzo obiettivo consiste nella progettazione di un framework di backtesting rigoroso e coerente con le condizioni operative dei sistemi quantitativi. Il framework adottato in questa tesi integra diversi elementi chiave:

- walk-forward validation, che simula l'aggiornamento progressivo dei modelli e garantisce previsioni interamente out-of-sample;
- modellazione esplicita dei costi di transazione, costruiti in funzione della volatilità condizionata stimata tramite modelli GARCH(1,1) con innovazioni t-Student;
- slippage e frizioni di mercato, rilevanti soprattutto nei dati intraday;
- metriche di rischio avanzate, tra cui Sharpe ratio, Sortino ratio, Max Drawdown, Calmar ratio e misure di rischio di coda come VaR ed ES empirici.

L'obiettivo finale è verificare se un modello predittivo statisticamente valido sia effettivamente in grado di generare una strategia operativa robusta e sostenibile, valutando il rapporto tra rendimento e rischio reale.

1.3 Confronto con i lavori scientifici esistenti

Rispetto ai contributi della letteratura recente, il lavoro proposto introduce una serie di ampliamenti, integrazioni e differenze metodologiche. Per comprendere in che modo l'elaborato si colloca nel panorama scientifico, è utile confrontare i tre studi principali presi a riferimento:

1) Krauss, Do e Huck (2017): 'Deep Neural Networks, Gradient-Boosted Trees, Random Forests: Statistical arbitrage on the S&P 500'

Il lavoro di Krauss et al. Analizza strategie di arbitraggio statistico[4] sullo S&P 500 utilizzando Reti

[4] L'arbitraggio statistico è una strategia quantitativa che sfrutta modelli statistici per individuare e trarre profitto da

Neurali Semplici (DNN), Random Forest e Gradient Boosted Trees. Gli autori mostrano che i modelli di ML, addestrati su rendimenti ritardati, possono generare segnali predittivi che portano a performance positive anche dopo la considerazione dei costi di transazione. La presente tesi tenta di ampliare quindi il lavoro di Krauss et al.:

- introducendo modelli ibridi che combinano componenti lineari e non lineari;
- impiegando una walk-forward validation;
- utilizzando una modellazione più realistica di slippage e costi.

2) Saifan et al. (2020): 'Investigating algorithmic stock market trading using ensemble Machine Learning methods'

Saifan et al. Propongono un framework di previsione dei prezzi tramite indicatori tecnici e algoritmi ensemble, come Random Forest e Gradient Boosting. Il contributo principale del lavoro è mostrare che combinazioni non lineari di indicatori standard possono migliorare la previsione della direzione dei prezzi. La presente tesi tenta di ampliare quindi il lavoro di Saifan et al.:

- introducendo un framework predittivo più avanzato, basato su modelli econometrici e ML/DL;
- utilizzando una walk-forward validation;
- enfatizzando una modellazione rigorosa dei costi di transazione e dello slippage;
- includendo strumenti di interpretabilità (SHAP, feature importance), assenti negli studi originali.

3) Stempień e Ślepaczuk (2025): 'Hybrid Models for financial forecasting: Combining Econometric, Machine Learning, and Deep Learning models'

Questo lavoro è il più vicino alla prospettiva della tesi, poiché propone l'integrazione tra ARIMA/ARFIMA e modelli ML/DL. Gli autori mostrano che i modelli ibridi possono catturare meglio le dinamiche lineari e non lineari, producendo un miglioramento della previsione rispetto a quelli singoli. La presente tesi tenta di ampliare quindi il lavoro di Stempień e Ślepaczuk introducendo:

- un framework più completo di gestione del rischio e dei costi operativi;
- una metodologia walk-forward pienamente implementata;
- l'uso di tecniche di interpretabilità come SHAP, che rendono i risultati più trasparenti;
- una comparazione più ampia tra ibridi di ML/DL.

1.4 Trading quantitativo e trading algoritmico: definizioni e caratteristiche

Il trading quantitativo e il trading algoritmico rappresentano due concetti strettamente collegati, ma non equivalenti [1]. Il trading quantitativo fa riferimento all'utilizzo di modelli matematici, statistici o econometrici per analizzare i mercati finanziari, formulare ipotesi e costruire segnali operativi [1]. In senso ampio, esso riguarda quindi l'intero processo di modellizzazione e valutazione delle strategie, indipendentemente dal fatto che l'esecuzione sia automatizzata o meno [1]. Il trading algoritmico, invece, ne rappresenta l'estensione operativa e tecnologica. Ovvero, consiste nell'implementare tali modelli in un sistema informatico che genera ed esegue automaticamente gli ordini [1]. La distinzione tra i due termini è essenziale in ambito accademico, poiché chiarisce il ruolo della modellistica statistica rispetto all'automazione delle decisioni. Come evidenzia Halls-Moore in 'Successful Algorithmic Trading', l'elemento qualificante del trading algoritmico è proprio la totale automazione del processo decisionale: "Il trading algoritmico, come definito qui, è l'uso di un sistema automatizzato per effettuare operazioni, che vengono eseguite in modo predeterminato tramite un algoritmo specificatamente senza l'intervento umano"[5] [1]. Questa caratteristica lo distingue da approcci quantitativi 'manuali', nei quali il modello matematico può guidare il trader, ma non sostituirlo. Viceversa, il trading quantitativo si focalizza sulla costruzione della strategia e dei modelli. Nella letteratura su tali sistemi, Saifan et al. Ricordano che lo scopo principale è utilizzare in modo rigoroso strumenti di analisi dei dati e previsione per supportare decisioni finanziarie oggettive,

inefficienze temporanee nei prezzi dei titoli.

[5] "Algorithmic trading, as defined here, is the use of an automated system for carrying out trades, which are executed in a pre-determined manner via an algorithm specifically without any human intervention"

osservando che questo approccio "elimina ogni fattore emotivo e psicologico che potrebbe affliggere qualsiasi trade operata dall'investitore"[6] [4]. La riduzione del bias umano e l'automazione operativa sono dunque un obiettivo metodologico di tale scienza [1]. Nel contesto della presente tesi, il focus principale riguarda le strategie di trading quantitativo e i modelli predittivi che ne costituiscono il nucleo, mentre gli aspetti di automazione vengono trattati come componente funzionale del backtesting e dell'esecuzione simulata.

1.5 Architettura di un sistema di trading

Un sistema di trading quantitativo-algoritmico può essere immaginato come un insieme coerente di moduli che, interagendo tra loro, permettono di trasformare dati grezzi in decisioni operative e strategie verificabili tramite simulazione [1][2]. Sebbene nella letteratura più avanzata queste componenti siano trattate con notevole complessità, è utile mantenere un'architettura chiara, intuitiva e facilmente riconducibile ai principi fondamentali del metodo scientifico. La struttura tipica comprende quattro blocchi principali, inoltre è utile immaginarli non come moduli chiusi ma come un flusso circolare [1][2] (si veda Figura 1):

1) Data (handling e preprocessing)

Il primo modulo riguarda la gestione dei dati, cioè tutte le operazioni necessarie per ottenere dati affidabili, coerenti e utilizzabili per la modellazione. Questo passaggio è cruciale perché la qualità delle informazioni influenza in modo diretto l'affidabilità dei modelli [1]. Errori, outlier o serie scorrette possono generare segnali completamente distorti. Come sottolinea Halls-Moore: "dataset a basso costo o gratis […] sono molto suscettibili ai valori 'anomali' […] Ciò significa che se la tua strategia di trading fa largo uso specificatamente di qualsiasi punto OHLC, la performance del backtest può differire da quella live"[7] [1]. Questa osservazione evidenzia che il primo compito di un ricercatore quantitativo è verificare che i dati siano coerenti (assenza di duplicati, incongruenze, salti anomali), completi (assenza di buchi temporali non giustificati) e rappresentativi del mercato che si vuole modellare [1]. Nel data handling ricadono:

- raccolta dei dati;
- pulizia delle serie;
- normalizzazione e trasformazioni;
- costruzione del dataset finale per la modellazione predittiva.

Si tratta del modulo più 'silenzioso' ma spesso il più critico, poichè un buon modello può fallire miseramente se alimentato con informazioni incoerenti [1].

2) Signal generation

Il secondo modulo è dedicato alla generazione dei segnali, ossia alla componente esplicitamente predittiva del sistema di trading quantitativo. È in questa fase che il modello tenta di stimare l'evoluzione futura del mercato sulla base delle informazioni passate e correnti. La 'signal generation' rappresenta dunque il cuore matematico e statistico dell'intero framework, poiché qui si determina se esistono condizioni sufficientemente robuste per ipotizzare una futura variazione positiva o negativa del prezzo, un incremento della volatilità o la presenza di un regime di mercato specifico [1]. Dal punto di vista concettuale, la natura predittiva del modulo deriva dal fatto che ogni modello impiegato, Econometrico, di Machine Learning o di Deep Learning, è progettato per formalizzare una relazione causale o statistica tra variabili osservate e un outcome non ancora realizzato. In altre parole, il modello non descrive semplicemente il comportamento passato dei prezzi, ma tenta di stimare come tali dinamiche si evolveranno, fornendo indicazioni operative basate su previsioni. L'obiettivo primario del modulo è dunque quello di generare una previsione statistica, ovvero un valore atteso di rendimento, una probabilità direzionale (up/down), un livello di volatilità, o un segnale derivato da una soglia decisionale [1]. L'algoritmo, una volta addestrato, restituisce un output che sintetizza la sua 'opinione statistica' sul comportamento futuro del mercato [1]. Il processo può essere scomposto

[6] "eliminates any emotional and psychological factors that might affect any trade undertaken by an investor"

[7] "cheap or free datasets [...] are very susceptible to 'outlying' values [...] This means that if your trading strategy makes extensive use of any of the OHLC points specifically, backtest performance can differ from live performance"

in tre momenti:

- Input: il modello riceve dati puliti e trasformati attraverso il processo di feature engineering, includendo prezzi, rendimenti, indicatori tecnici, volatilità e altre variabili informative
- Modello: il sistema stima la relazione tra input e target attraverso addestramento, ottimizzazione e validazione su dati non visti.
- Output: viene prodotta una previsione (direzione, rendimento, volatilità) che viene convertita in un segnale.

È fondamentale sottolineare che il segnale predittivo non corrisponde ancora ad un'operazione di trading, ma costituisce una decisione teorica, un'indicazione basata sulla previsione statistica del modello. Il suo scopo è rispondere alla domanda cardine dell'intero sistema 'Esistono condizioni statistiche sufficienti per aprire o chiudere una posizione sul mercato?' [1]. Solo dopo questa valutazione predittiva intervengono gli altri moduli che trasformano il segnale in un'operazione reale.

3) Risk management

Il terzo modulo ha il ruolo di trasformare un buon modello in una strategia sostenibile. Anche se quest'ultimo avesse un'elevata accuratezza predittiva, potrebbe fallire se la gestione del rischio non è adeguata, infatti molti modelli che performano bene in test puramente predittivi, non reggono quando si passa alla considerazione del rischio [1][2]. I costi operativi stessi diventano parte integrante del risk management, non soltanto del modulo di esecuzione. Il risk management comprende principalmente [1][2]:

- controllo della volatilità;
- dimensionamento della posizione;
- stop loss e take profit dinamici;
- limiti di esposizione e leva;
- metriche di performance aggiustate per il rischio.

4) Execution e implementazione operativa

Qui si traducono i segnali in operazioni effettive. Anche se nel presente lavoro non è implementato un sistema live, l'esecuzione simulata nel backtest deve rispettare il più possibile la realtà dei mercati [1][2]. Allo stesso modo, Krauss et al. Mostrano come gli ensemble ML passino da performance elevate a risultati molto più modesti dopo costi e slippage: " i rendimenti peggiorano […] dopo i costi di transazione"[8] [3]. Più la frequenza è alta (es. intraday 5 minuti), maggiore è l'importanza di questa sezione, infatti per frequenze giornaliere, i costi contano meno ma restano determinanti [1]. L'execution considera, in linea di massima:

- costi di commissione;
- spread denaro-lettera[9];
- slippage simulato (dovuto a volatilità o volume);
- impatto sul mercato (market impact);
- latenza.

Questa architettura verrà approfondita nei paragrafi e capitoli successivi, in particolare nel framework sperimentale del Capitolo 3.

[8] "returns deteriorate [...] after transaction costs"

[9] Lo spread denaro-lettera è la differenza tra il miglior prezzo a cui qualcuno è disposto ad acquistare un asset finanziario (denaro) e il miglior prezzo a cui qualcuno è disposto a venderlo (lettera)

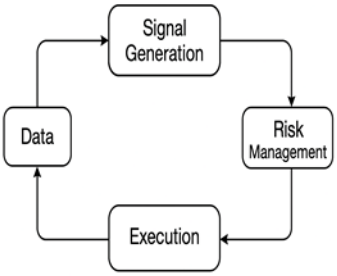

Figura 1 - Architettura di un sistema di trading quantitativo-algoritmico

1.6 Metodologia scientifica nello sviluppo di strategie

Lo sviluppo di una strategia di trading quantitativo richiede un approccio rigoroso e strutturato, basato sui principi del metodo scientifico, così che l'obiettivo non sia semplicemente costruire un modello in grado di 'funzionare' sui dati storici, ma definire un processo che permetta di verificare, falsificare e migliorare ipotesi in modo replicabile e privo di distorsioni [1]. Per questo motivo è utile sintetizzare una logica iterativa in cui osservazione, modellazione, valutazione e revisione si susseguono in cicli continui [1]:

1) Osservazione e formulazione dell'ipotesi

La prima fase consiste nell'osservare i mercati alla ricerca di regolarità, inefficienze o comportamenti ricorrenti. Può trattarsi, ad esempio di una relazione tra volatilità e rendimenti futuri, di pattern di momentum o mean reversion, di effetti legati all'ordine temporale, ecc… Conseguentemente nasce un'ipotesi formulata in modo chiaro e verificabile, per esempio 'La previsione della direzione del rendimento a 1 giorno è migliorata integrando una componente lineare (ARIMA) con un modello non lineare (Random Forest).' Il lavoro di Stempień e Ślepaczuk segue esattamente questo approccio, ipotizzando che l'integrazione lineare–non lineare sia vantaggiosa perché "l'ibridazione si basa sul presupposto che questi modelli riusciranno a estrarre sequenzialmente sia i modelli lineari che quelli non lineari nei dati"[10] [5]

2) Costruzione e addestramento del modello

Una volta formulata l'ipotesi, viene definito il modello o l'insieme di modelli da utilizzare. Nel nostro caso può essere l'utilizzo ibrido combinando più approcci. La costruzione del sistema di previsione richiede inoltre:

- definizione delle feature;
- scelta dell'orizzonte predittivo;
- selezione degli iperparametri;
- scelta della frequenza dei dati.

3) Backtesting e validazione

Una strategia non può essere considerata valida se non supera una valutazione empirica [1]. Il backtest è il procedimento che consiste nell'applicare il modello ai dati storici non utilizzati in fase di addestramento per valutarne il comportamento, riducendo sensibilmente il rischio di risultati distorti. In questo contesto risulta fondamentale la separazione netta tra training e test, l'inclusione di costi e slippage e la valutazione tramite l'utilizzo di metriche corrette. Attraverso un backtesting rigoroso si possono evitare possibili problemi come l'overfitting e l'eccessivo turnover[11].

4) Valutazione delle performance e analisi critica

Una volta completato il backtest, le performance vanno analizzate secondo criteri rigorosi, anche tramite la validazione della robustezza del modello su diversi regimi di mercato. Questo principio ribadisce l'importanza di non basarsi solo sulla predittività, ma anche sulla sostenibilità economica

[10] "the hybridization relies on the assumption that these models will manage to sequentially extract both the linear and nonlinear patterns in the data"

[11] Il turnover è la quantità di portafoglio che viene comprata o venduta in un periodo, indicando quanto spesso la strategia cambia posizione.

delle strategie, oltre che sull'interpetrabilità [1].

5) Iterazione, raffinamento e possibile implementazione

Il metodo scientifico non si conclude con un singolo backtest, ogni risultato genera nuove domande, miglioramenti e varianti del modello. La strategia viene raffinata iterativamente fino a raggiungere un equilibrio tra coerenza teorica e robustezza empirica, tra semplicità operativa e sostenibilità economica. La fase finale, non oggetto diretto di questa tesi ma parte integrante del ciclo quantitativo, è l'implementazione in produzione.

1.7 Struttura dell'elaborato

La struttura dell'elaborato riflette questo percorso:

- Il Capitolo 1 ha introdotto il quadro teorico del trading quantitativo, le sue componenti fondamentali e le criticità della valutazione;
- il Capitolo 2 presenta i modelli predittivi, Econometrici, di Machine Learning e Deep Learning utilizzati, insieme alle tecniche di validazione;
- il Capitolo 3 presenta il framework sperimentale implementato, comprendente dati, preprocessing, feature engineering, tecniche di validazione e metriche di valutazione;
- il Capitolo 4 riporta i risultati sperimentali: confronto tra modelli ibridi, valutazione dei costi e delle metriche di rischio;
- il Capitolo 5 conclude con considerazioni critiche e possibili sviluppi futuri.

L'obiettivo complessivo è valutare se e in quale misura un approccio ibrido possa migliorare la previsione dei mercati e generare strategie di trading più robuste rispetto ai modelli tradizionali, cercando di fornire un contributo originale nel contesto degli studi applicati su tale tematica.

2 Modelli predittivi

2.1 Introduzione ai modelli predittivi

Nel trading quantitativo, i modelli predittivi costituiscono il nucleo del processo di generazione dei segnali operativi [1][2]. Essi hanno il compito di trasformare informazioni storiche, tipicamente rendimenti, volatilità e altre grandezze rilevanti, in una stima della dinamica futura della variabile di interesse, nel nostro caso il rendimento del giorno successivo [1][5]. L'idea centrale è che, pur in presenza di elevato rumore e apparente imprevedibilità, i mercati possano mostrare pattern strutturali, dipendenze temporali, episodi di regime switching o forme di persistenza sfruttabili a fini previsivi [2][5]. In questa tesi vengono considerate tre grandi famiglie di modelli predittivi:

1) Modelli Econometrici tradizionali (ARIMA e ARFIMA), utilizzati per catturare le eventuali strutture lineari nella serie dei rendimenti [2][5];
2) Modelli di apprendimento automatico (Logistic Regression, Random Forest, XGBoost), adatti a cogliere relazioni non lineari e interazioni complesse tra le feature [2-5];
3) Modelli di Deep Learning, rappresentati dalle LSTM, progettate per apprendere pattern dinamici in sequenze temporali rumorose [3][5].

Queste tre classi vengono impiegate in forma ibrida, dove le previsioni dei modelli Econometrici fungono da feature aggiuntive per gli algoritmi di Machine Learning e Deep Learning. Tale approccio consente di combinare la capacità dei modelli lineari di catturare dipendenze a breve termine con la flessibilità dei modelli non lineari [5].

2.2 Modelli Econometrici tradizionali

I modelli Econometrici costituiscono la base teorica per la modellazione delle serie temporali [2]. In particolare, autocorrelazioni di breve periodo, dinamiche stazionarie e volatilità non costante [2]. ARIMA e ARFIMA sono modelli adatti a descrivere relazioni lineari nella serie, mentre GARCH viene utilizzato per modellare la volatilità condizionata [2].

2.2.1 Modelli AR, MA e ARIMA

Il modello ARIMA rappresenta una combinazione di tre componenti:

- AR (autoregressiva), per modellare la dipendenza dai valori passati;
- MA (moving average), per modellare la dipendenza dagli shock passati;
- I (integrazione), per rendere la serie stazionaria.

Nel contesto dei rendimenti giornalieri di asset altamente volatili come Bitcoin, il potere predittivo di ARIMA tende ad essere limitato, ma la sua interpretabilità lo rende un ottimo modello di base [5]. Nel framework di questa tesi, ARIMA viene applicato tramite walk-forward expanding window, e la sua previsione $\hat{r}_{t+1}^{ARIMA}$ viene trattata come feature esplicativa nella pipeline ibrida con i modelli non lineari.

2.2.2 Modello ARFIMA

Il modello ARFIMA introduce l'integrazione frazionale, che consente di rappresentare fenomeni di memoria di lungo periodo [5]. Sebbene i rendimenti finanziari mostrino generalmente memoria breve, in alcuni casi il modello ARFIMA può catturare comportamenti persistenti non rappresentabili con ARIMA [5]. Analogamente ad ARIMA, anche ARFIMA viene impiegato nel nostro framework come fonte di informazione lineare, la previsione $\hat{r}_{t+1}^{ARFIMA}$ costituisce una feature aggiuntiva per i modelli di Machine Learning e Deep Learning.

2.2.3 Modelli GARCH

Il modello GARCH (Generalized Autoregressive Conditional Heteroskedasticity) viene utilizzato esclusivamente per stimare la volatilità condizionata [2]. Bitcoin mostra tipici cluster di volatilità e code pesanti, per questo motivo è stato adottato un modello GARCH (1,1) con innovazioni t-Student [2]. Nel contesto della tesi, GARCH ricopre due ruoli specifici, ovvero fornire una misura dinamica

del rischio per il calcolo di VaR[12], ES[13] e CVaR[14] e determinare costi di transazione dinamici, crescenti con la volatilità, nella valutazione delle strategie operative.

2.3 Modelli ML/DL

2.3.1 Modelli di Machine Learning

Gli algoritmi di Machine Learning vengono utilizzati per modellare relazioni non lineari o difficilmente rappresentabili dai modelli Econometrici [2-5]. Nel nostro framework sono stati adottati tre modelli ampiamente consolidati nella letteratura sul forecasting finanziario [3-5]:

1) Logistic Regression

Sebbene sia un modello lineare, la Regressione Logistica rappresenta un baseline importante per la classificazione direzionale, particolarmente interpretabile e utile per comprendere il contributo marginale delle feature [2]. Nel framework implementato, essa costituisce uno dei tre modelli che formano il classificatore ensemble.

2) Random Forest

La Random Forest è un algoritmo ensemble basato su alberi decisionali addestrati su sottoinsiemi casuali di dati e feature. È robusta al rumore, gestisce bene strutture non lineari e fornisce misure utili come la feature importance [2-4]. Nel nostro framework contribuisce alla componente non lineare dell'ensemble ML.

3) XGBoost

XGBoost è un algoritmo di boosting basato su gradient boosting su alberi. È uno dei modelli più efficaci nel contesto del forecasting finanziario di breve periodo, grazie alla capacità di catturare interazioni complesse e non linearità [4][5]. Nel nostro ensemble ML, XGBoost riveste il ruolo di modello dominante ed è anche il modello scelto per l'analisi di interpretabilità tramite SHAP nel Capitolo 4. Gli algoritmi di ML sopra esposti vengono impiegati come parte di un ensemble che combina le rispettive previsioni. L'ensemble è centrale nel lavoro sperimentale, poiché costituisce uno dei principali candidati per la generazione del segnale operativo.

2.3.2 Modelli di Deep Learning

Il Deep Learning, e in particolare le Reti Ricorrenti, rappresenta una classe di modelli progettata per apprendere pattern sequenziali nei dati [3][5]. In ambito finanziario, le LSTM sono particolarmente diffuse, poiché mitigano il problema del vanishing gradient[15] e consentono di modellare dipendenze temporali più estese rispetto ai modelli econometrici [3][5]. Nel nostro framework, la LSTM viene utilizzato come benchmark avanzato rispetto ai modelli lineari e ML e componente non lineare nei modelli ibridi basati su previsioni ARIMA o ARFIMA.

2.4 Modelli ibridi

I modelli ibridi combinano una componente lineare, modellata tramite ARIMA o ARFIMA, con una componente non lineare, modellata tramite ensemble ML o LSTM. Tuttavia, è importante chiarire che nella presente tesi non viene utilizzato il paradigma residual-based spesso discusso in letteratura, in cui il modello lineare genera residui da dare in input al modello non lineare [5]. Il framework implementato adotta invece un modello ibrido basato su feature additive, nel quale:

$$x_t^{(ARIMA)} = \hat{r}_{t+1}^{ARIMA}, x_t^{(ARFIMA)} = \hat{r}_{t+1}^{ARFIMA}$$

[12] Il VaR è la perdita massima attesa di un portafoglio entro un certo orizzonte temporale e con un dato livello di confidenza.

[13] Il Expected Shortfall (ES) è la perdita media nelle peggiori code della distribuzione, cioè oltre il VaR, a un dato livello di confidenza

[14] Il CVaR è la perdita media attesa oltre il VaR, cioè la media delle peggiori perdite che superano la soglia del Value at Risk.

[15] Il vanishing gradient è il problema per cui, durante il training, i gradienti diventano troppo piccoli e impediscono alla rete neurale di aggiornare efficacemente i pesi negli strati profondi.

sono inserite direttamente come feature aggiuntive nel dataset utilizzato. Questa scelta evita l'introduzione di rumore tramite residui difficili da modellare, inoltre mantiene parsimonia nella costruzione delle feature e semplifica il processo di validazione walk-forward.

2.5 Tecniche di validazione per Serie Temporali

La validazione riveste un ruolo fondamentale nel trading quantitativo, poiché consente di verificare se il modello sia veramente in grado di generalizzare il proprio comportamento su dati non osservati [1]. A differenza dei problemi classici di Machine Learning, nelle serie temporali l'ordine dei dati è essenziale, i valori futuri non possono essere utilizzati per prevedere quelli passati, e le osservazioni sono spesso autocorrelate [2]. Per questo motivo, tecniche di validazione casuali o basate su shuffle, molto diffuse in altri ambiti, non sono utilizzabili, poiché introdurrebbero gravi errori di valutazione e fenomeni come il data leakage[16] [1][2]. La validazione deve quindi rispettare la dimensione temporale della serie, mantenendo la separazione naturale tra passato (training) e futuro (test) [1][2]. In questa tesi viene adottata la walk-forward validation, centrale nel framework sperimentale. Essa rappresenta la tecnica più realistica e coerente con le esigenze del trading quantitativo [1][5], infatti il suo obiettivo è replicare il modo in cui un modello verrebbe effettivamente utilizzato in produzione: addestrato su dati passati, testato su dati futuri immediatamente successivi, aggiornato e poi nuovamente testato. La procedura si articola tipicamente in quattro fasi:

1) Addestramento iniziale su un primo segmento di dati (training window).
2) Test sul segmento temporale successivo (test window).
3) Avanzamento della finestra, una parte dei dati più recenti viene aggiunta alla finestra di training, mentre la finestra di test si sposta in avanti.
4) Ripetizione del processo fino alla fine della serie.

Questo meccanismo consente di valutare il modello su molteplici periodi consecutivi e in condizioni di mercato diverse, simulando la necessità di aggiornare periodicamente il modello sulla base dei nuovi dati [5]. La walk-forward validation presenta tre vantaggi principali:

- rispetta rigidamente la struttura temporale, evitando qualsiasi forma di data leakage [1][5];
- simula il comportamento reale del modello, che deve essere periodicamente riaddestrato e valutato [5];
- riduce il rischio di overfitting, poiché obbliga la generalizzazione più volte su dati nuovi [5].

Per questi motivi, la walk-forward validation costituisce la metodologia centrale del presente elaborato e viene utilizzata per valutare, in modo coerente e robusto, la capacità predittiva e operativa.

[16] Il data leakage è l'errore di validazione che si verifica quando informazioni del dataset di test (o future) finiscono impropriamente nel training, falsando le prestazioni stimate del modello.

3 Framework sperimentale

3.1 Obiettivi del framework sperimentale

L'obiettivo del framework sperimentale è valutare la capacità predittiva di modelli statistici, algoritmi di apprendimento automatico ed architetture di Deep Learning nel prevedere il segno del rendimento giornaliero di Bitcoin, nonché analizzare la trasferibilità di tali modelli in termini operativi mediante strategie direzionali long/short. L'intero processo è costruito secondo una pipeline rigorosa:

1) acquisizione e pulizia dei dati;
2) feature engineering minimale orientata alla parsimonia;
3) definizione del target, configurazione dei modelli;
4) validazione walk-forward;
5) valutazione tramite metriche predittive e operative.

La progettazione segue un approccio completamente time-consistent, nel quale la costruzione delle feature, l'addestramento dei modelli e la generazione delle previsioni rispettano la causalità temporale e garantiscono che tutte le metriche siano effettivamente fuori campione.

3.2 Dati e universo di riferimento

3.2.1 Scelta dell'asset e orizzonte temporale

L'asset scelto per l'analisi è Bitcoin quotato in dollari statunitensi (BTC-USD), uno degli strumenti finanziari più volatili e liquidi nel panorama crypto [5]. La forte presenza di cluster di volatilità, il comportamento leptocurtico dei rendimenti e la relativa inefficienza informativa documentata in letteratura rendono Bitcoin un candidato ideale per studiare la capacità predittiva di modelli lineari e non lineari [5]. L'orizzonte temporale dell'analisi daily copre il periodo dal 1 gennaio 2017 al 31 dicembre 2024, che include differenti fasi di mercato, tra cui bull-run, drawdown prolungati e periodi di consolidamento laterale.

3.2.2 Fonti dei dati

I dati giornalieri sono stati acquisiti tramite Yahoo Finance mediante il pacchetto yfinance, includendo i prezzi Open–High–Low–Close (OHLC) e i volumi giornalieri. Vengono mantenuti i prezzi non aggiustati, al fine di preservare l'integrità della serie e mantenerla coerente con i modelli di volatilità utilizzati.

3.2.3 Struttura delle serie e variabili di base

A partire dalla serie dei prezzi di chiusura P_t, è stato calcolato il rendimento logaritmico giornaliero secondo la formula:

$$r_t = \ln(P_t) - \ln(P_{t-1}),$$

che rappresenta la trasformazione standard nella modellazione delle serie finanziarie. Il log-return è infatti ampiamente utilizzato nei modelli di Time Series Analysis grazie alle sue proprietà matematiche e alla capacità di rendere più trattabile la dinamica percentuale dei prezzi [2]. Esso costituisce inoltre la variabile fondamentale sia per l'applicazione dei modelli statistici sia per la definizione del target direzionale impiegato nelle procedure di classificazione [2]. Le analisi descrittive preliminari evidenziano la presenza di leptocurtosi e asimmetrie, tali proprietà suggeriscono che la volatilità non sia costante nel tempo, confermando la necessità di adottare modelli in grado di rappresentare eteroschedasticità condizionata e code pesanti. In questo contesto, l'utilizzo di un modello GARCH(1,1) con innovazioni t-Student risulta particolarmente appropriato, esso è infatti progettato per catturare fenomeni di clustering della volatilità e per adattarsi a distribuzioni con code più pronunciate rispetto alla normale [2].

3.3 Preprocessing e data cleaning

Il preprocessing dei dati rappresenta una fase essenziale per garantire la qualità e l'affidabilità delle analisi successive. In primo luogo, vengono rimossi eventuali valori mancanti presenti nel dataset, al fine di evitare distorsioni o instabilità nei modelli previsivi. Un'attenzione particolare è rivolta anche alla verifica della coerenza della frequenza temporale, così da garantire che ogni osservazione rappresenti effettivamente un intervallo giornaliero e che non siano presenti duplicati, salti di calendario o irregolarità nella serie. Una volta ripulita e strutturata la serie dei prezzi, vengono calcolati i rendimenti logaritmici e creati gli eventuali shift temporali necessari per l'addestramento dei modelli predittivi, in particolare quelli che richiedono la costruzione di lag o variabili derivate. Al termine di queste operazioni, il dataset risultante è completamente privo di valori mancanti, correttamente ordinato nel tempo e presenta una struttura semplice e lineare. Tale configurazione è pienamente idonea all'applicazione dei modelli econometrici (ARIMA/ARFIMA), degli algoritmi di apprendimento automatico e delle Reti Neurali Ricorrenti, garantendo una base solida per la fase di modellazione e per la successiva valutazione delle performance.

3.4 Feature engineering

Seguendo l'impostazione proposta da Stempień & Słepaczuk (2025), si è preferito evitare l'inclusione di un numero elevato di feature tecniche o residui complessi, al fine di ridurre il rischio di overfitting e mantenere elevata interpretabilità del modello [5]. Il set di feature utilizzato è composto esclusivamente da:

- ritardi dei rendimenti logaritmici:

$$r_{t-1}, r_{t-2}, r_{t-3}, r_{t-5}$$

- previsioni ARIMA(…)+walk-forward:

$$\hat{r}_{t+1}^{ARIMA}$$

- previsioni ARFIMA(…)+walk-forward:

$$\hat{r}_{t+1}^{ARFIMA}$$

Questa scelta riflette un'impostazione rigorosa, coerente con il principio di 'parsimonia statistica', in cui le feature utilizzate sono esclusivamente quelle supportate empiricamente [5]. L'assenza di indicatori tecnici, trasformazioni avanzate dei volumi o residui econometrici come variabili è una scelta intenzionale, coerente con l'assunto che nei timeframe giornalieri gli indicatori tecnici e le feature altamente derivate non migliorano la stabilità del potere predittivo e tendono anzi ad aumentare il rischio di overfitting [3][5].

3.5 Definizione dei target e configurazioni dei modelli

3.5.1 Target di classificazione direzionale

Per i modelli di classificazione, l'obiettivo principale consiste nel prevedere la direzione del rendimento del giorno successivo, trasformando il problema in una classificazione binaria. Il target è definito come:

$$y_t = \begin{cases} 1 & \text{se } r_{t+1} > 0, \\ 0 & \text{altrimenti.} \end{cases}$$

Una formulazione di questo tipo è ampiamente utilizzata nella letteratura sul forecasting direzionale dei mercati finanziari, in particolare negli studi basati su modelli ML e DL applicati a rendimenti giornalieri [3][4][5]. Parallelamente, nelle versioni dei modelli orientate alla regressione, si utilizza direttamente la variabile continua:

$$y_{\text{reg}} = r_{t+1},$$

coerentemente con l'approccio standard di modellazione econometrica dei rendimenti [2][5].

3.5.2 Modelli singoli

La fase sperimentale include tre famiglie di modelli, tutte ampiamente consolidate nella letteratura sui mercati finanziari:

- Modelli statistici lineari (ARIMA, ARFIMA), impiegati per rilevare eventuali dipendenze lineari e strutture di memoria a breve o lungo termine nella serie dei rendimenti [2][5];
- Modelli di apprendimento automatico (Logistic Regression, Random Forest, XGBoost), utilizzati per identificare relazioni non lineari e interazioni complesse tra le variabili [2][3][4][5];
- Modelli di deep learning (LSTM), progettati per apprendere pattern sequenziali e dipendenze temporali più estese, risultando particolarmente efficaci in scenari caratterizzati da elevata volatilità [3][5].

Tutti gli algoritmi vengono addestrati tramite walk-forward validation, una tecnica che garantisce la separazione tra passato e futuro ed evita qualsiasi forma di data leakage [1][5]. Questa procedura assicura che il training avvenga utilizzando esclusivamente informazioni storiche disponibili fino a quel momento, condizione necessaria nel trading quantitativo.

.

3.5.3 Modelli ibridi lineare–non lineare

Accanto ai modelli singoli, la sperimentazione prevede la costruzione di modelli ibridi, che combinano una componente lineare e una non lineare [5]. La prima, costituita dai modelli ARIMA o ARFIMA, viene stimata tramite una finestra espandente e aggiornata progressivamente lungo l'orizzonte temporale. La componente non lineare (ensemble ML o LSTM), invece, riceve come input aggiuntivo la previsione lineare ottenuta dal modello Econometrico:

$$x_t^{(\mathrm{ARIMA})} = \hat{r}_{t+1}^{\mathrm{ARIMA}}, x_t^{(\mathrm{ARFIMA})} = \hat{r}_{t+1}^{\mathrm{ARFIMA}}.$$

L'integrazione delle previsioni lineari come feature additive rappresenta uno degli approcci più recenti e robusti discussi nella letteratura sui modelli ibridi, in alternativa al paradigma residual-based. Infatti, come evidenziato da Stempień & Słepaczuk (2025), la strategia basata sui residui non sempre produce benefici, specialmente nei mercati ad elevato rumore, e può addirittura incrementare l'instabilità del processo di apprendimento [5]. Per questo motivo, nel presente lavoro non vengono utilizzati i residui ARIMA/ARFIMA come feature, poiché i test preliminari e le evidenze presenti in letteratura [3][4][5] non mostrano contributi predittivi significativi aggiuntivi rispetto all'utilizzo diretto delle previsioni lineari. Questa scelta è coerente con il principio di parsimonia e con la necessità di evitare complessità strutturali non giustificate, riducendo al minimo il rischio di overfitting.

3.5.4 Schema di validazione temporale

L'intero framework utilizza una validazione walk-forward expanding window. Per ogni giorno t il modello viene addestrato su dati dal giorno iniziale fino a t, dopo di che viene prodotta una previsione per $t + 1$ e aggiornata la finestra espandente. Questo impianto metodologico consente di operare in un contesto pienamente coerente dal punto di vista temporale e garantisce diversi vantaggi fondamentali. In primo luogo, assicura l'assenza di look-ahead bias[17], poiché nessuna informazione futura viene utilizzata, né direttamente né indirettamente, nella costruzione delle feature o nell'addestramento dei modelli [1][5]. In secondo luogo, viene preservata la causalità, condizione necessaria affinché i risultati previsivi siano interpretabili e replicabili in un contesto operativo reale [1][5]. L'approccio coerente nel tempo permette inoltre una comparabilità effettiva tra modelli di natura diversa, lineari, di apprendimento automatico e reti LSTM, poiché tutti vengono valutati sotto le stesse condizioni sperimentali. Infine, l'intera procedura produce serie predittive completamente out-of-sample, elemento essenziale per misurare con affidabilità la reale capacità dei modelli di

[17] I look-ahead bias sono errori di backtest che avvengono quando una strategia usa informazioni future non disponibili al momento della decisione.

generalizzare e per stimare performance operative non influenzate da artefatti metodologici [1][5].

3.6 Costruzione delle strategie di trading

3.6.1 Segnale operativo

A partire dalle previsioni restituite dai modelli di classificazione, viene costruita una semplice strategia direzionale long/short. In particolare:

- se il modello prevede un movimento rialzista, viene aperta una posizione long $(+1)$;
- se il modello prevede un movimento ribassista, viene assunta una posizione short (-1).

Il rendimento associato alla strategia per il giorno tè definito come:

$$r_t^{\text{strat}} = \text{signal}_t \cdot r_{t+1},$$

dove signal_t rappresenta il segnale direzionale generato dal modello e r_{t+1} è il rendimento realizzato il giorno successivo. Questa formulazione segue gli standard dei backtest direzionali basati su segnali, in cui la performance è calcolata come combinazione del segnale e del movimento effettivo del mercato [1]. Il valore così ottenuto rappresenta il rendimento grezzo della strategia, non ancora corretto per i costi di negoziazione. In una fase successiva vengono applicati costi di transazione dinamici, modellati in funzione della volatilità, al fine di ottenere una misura più realistica della performance netta [5].

3.6.2 Modellazione di costi di transazione e volatilità

I costi operativi della strategia vengono modellati come funzione della volatilità condizionata stimata tramite un modello GARCH (1,1) con innovazioni t-Student [2]. La formulazione utilizzata è:

$$\text{Cost}_t = c_0 + c_1\, \sigma_t,$$

dove $\sigma_t$rappresenta la volatilità condizionata al tempo t, aggiornata dinamicamente sulla base delle informazioni più recenti. Questa scelta riflette l'evidenza empirica secondo cui slippage, spread e oneri di esecuzione tendono ad aumentare in condizioni di elevata volatilità, fenomeno particolarmente accentuato nei mercati caratterizzati da forte variabilità della liquidità, come le criptovalute [5]. La modellazione dei costi come funzione crescente della volatilità permette dunque di ottenere una stima più realistica delle performance operative, penalizzando opportunamente i periodi in cui il mercato è turbolento e le condizioni di negoziazione risultano meno favorevoli.

3.6.3 Metriche predittive e operative

La valutazione dei modelli predittivi e delle strategie di trading risultanti richiede l'adozione di un insieme articolato di metriche, in grado di misurare non solo la capacità discriminativa del modello, ma anche la sua traducibilità in rendimenti operativi corretti per il rischio. Le metriche predittive utilizzate includono:

- l'accuratezza, che quantifica la quota di previsioni corrette rispetto al totale;
- la ROC-AUC, che misura la capacità del modello di distinguere tra classi mediante l'analisi della curva Receiver Operating Characteristic;
- il recall per classe, utile per cogliere eventuali asimmetrie nella capacità del modello di identificare rendimenti positivi e negativi;
- la matrice di confusione, che fornisce una rappresentazione dettagliata delle classificazioni corrette ed errate.

Queste metriche permettono di comprendere fino a che punto il modello riesca a identificare la direzione del rendimento del giorno successivo, pur tenendo presente che elevata performance predittiva non implica necessariamente profitto operativo, soprattutto in presenza di costi di transazione e volatilità elevata. Parallelamente, per valutare la qualità delle strategie di trading

costruite sulla base delle previsioni, vengono utilizzate metriche di tipo operativo e risk-adjusted. Tra queste:

- il rendimento medio annualizzato e la volatilità annualizzata forniscono una prima fotografia del profilo rischio–rendimento della strategia;
- indici sintetici come lo Sharpe ratio e lo Sortino ratio consentono di confrontare strategie diverse tenendo conto rispettivamente della volatilità totale e della sola volatilità al ribasso;
- il Max Drawdown misura la massima perdita cumulata dal massimo storico successivo e rappresenta un indicatore cruciale della robustezza operativa;
- il Calmar ratio, dato dal rapporto tra rendimento annualizzato e drawdown massimo, fornisce invece una misura della sostenibilità della strategia nel lungo periodo.
- per caratterizzare il rischio di coda sono stati calcolati il VaR empirico al 95% (Value-at-Risk) e il corrispondente CVaR empirico (Conditional Value-at-Risk), che stimano la perdita massima attesa e la perdita media condizionata nelle peggiori giornate di mercato.

Tutte queste metriche sono calcolate esclusivamente su serie di rendimenti interamente out-of-sample, garantendo così un processo di valutazione robusto e privo di bias informativi.

4 Risultati sperimentali

4.1 Preprocessing dei dati giornalieri

L'analisi empirica condotta nel presente capitolo si basa sui dati giornalieri di Bitcoin quotato in dollari statunitensi (BTC-USD), scaricati attraverso l'interfaccia Yahoo Finance, mediante la libreria yfinance di Python. Tale fonte fornisce la serie storica dei prezzi Open, High, Low, Close, Adjusted Close e Volume con frequenza giornaliera. Il dataset originale, strutturato in formato MultiIndex (campo di prezzo e ticker), è stato preliminarmente normalizzato. In particolare, le colonne sono state appiattite in etichette univoche, convertite in minuscolo e armonizzate mediante l'aggiunta di una colonna esplicita date, ricavata dall'indice temporale. L'assenza di valori mancanti nei prezzi e nei volumi ha permesso di procedere senza ulteriori procedure di imputazione. Coerentemente con quanto discusso nel capitolo precedente, i rendimenti utilizzati come variabile di riferimento sono i rendimenti logaritmici. Tale scelta trova fondamento nella loro natura additiva nel tempo, caratteristica che ne facilita l'impiego in modelli econometrici e di apprendimento automatico [2]. Il rendimento è definito come:

$$r_t = \ln(P_t) - \ln(P_{t-1}),$$

dove P_t rappresenta il prezzo di chiusura alla data t e poiché il calcolo richiede l'osservazione precedente, la prima riga è stata rimossa. Una prima esplorazione descrittiva della serie dei rendimenti mostra proprietà tipiche delle serie finanziarie ad alta frequenza. La media campionaria risulta prossima allo zero, mentre la volatilità è elevata, in linea con l'elevata instabilità storicamente osservata nei prezzi delle criptovalute, caratterizzate da dinamiche particolarmente instabili e da un rapporto segnale–rumore molto ridotto [5]. L'analisi di forma evidenzia una asimmetria negativa (skewness = –0.667), indicativa di una maggiore frequenza di osservazioni caratterizzate da variazioni negative estreme, e una kurtosi elevata (kurtosis = 11.35), sintomo della presenza di code pesanti rispetto alla distribuzione normale. Tali caratteristiche suggeriscono un comportamento non-gaussiano della serie, con implicazioni dirette sulla modellizzazione econometrica e sulla stima del rischio. Le funzioni di autocorrelazione semplice (ACF) e parziale (PACF) non mostrano autocorrelazioni statisticamente rilevanti nei rendimenti, confermando l'assenza di memoria lineare di breve periodo. Tale proprietà verrà invece riscontrata nella volatilità, come discusso nelle sezioni successive dedicate ai modelli GARCH.

4.2 Modelli

4.2.1 ARIMA/ARFIMA + Ensemble ML

L'approccio ibrido sviluppato in questa sezione integra modelli Econometrici lineari (ARIMA e ARFIMA) con algoritmi di apprendimento automatico non lineari. L'idea alla base della modellazione ibrida è che i modelli ARIMA/ARFIMA catturino le dipendenze lineari e la componente a memoria lunga dei rendimenti, mentre i modelli di Machine Learning colgano strutture non lineari e interazioni complesse non rappresentabili in forma parametrica.

1) Componente Econometrica: ARIMA e ARFIMA

La prima parte dell'architettura prevede la stima di due modelli lineari sui rendimenti logaritmici:

- ARIMA (1,0,1), utilizzato come baseline lineare per catturare autocorrelazioni di breve periodo;
- ARFIMA, approssimato tramite:
  - differenziazione frazionaria della serie r_t con parametro $d = 0.4$,
  - stima di un modello ARMA(1,1) sulla serie differenziata.

Per entrambi i modelli si è adottato un walk-forward expanding window con ricalibrazione ogni 30

osservazioni (≈ mensile). Tale frequenza riproduce un contesto realistico di aggiornamento periodico dei parametri, il modello viene stimato sulla finestra $[1, t]$, produce una previsione per $t + 1$, quindi si espande la finestra includendo il dato successivo. Per ogni giorno t sono state generate due previsioni out-of-sample:

$$\hat{r}_{t+1}^{(\text{ARIMA})}, \hat{r}_{t+1}^{(\text{ARFIMA})},$$

successivamente impiegate come feature aggiuntive nei modelli di machine learning. Il dataset risultante comprende dunque:

- lag $r_{t-1}, r_{t-2}, r_{t-3}, r_{t-5}$;
- previsione ARIMA del rendimento a $t + 1$;
- previsione ARFIMA del rendimento a $t + 1$.

Questo insieme di variabili rappresenta simultaneamente memoria corta, memoria lunga e previsioni lineari, costituendo la base per la modellazione non lineare successiva.

2) Componente di Machine Learning: ensemble di modelli

Per la parte predittiva non lineare è stato costruito un ensemble eterogeneo, composto da tre modelli complementari:

- Logistic Regression (modello lineare, interpretabile);
- Random Forest (modello ad alberi completamente non lineare);
- XGBoost (modello di boosting largamente utilizzato in finanza quantitativa).

Ciascun modello produce una probabilità di rialzo per il giorno successivo:

$$p_t^{(LR)}, p_t^{(RF)}, p_t^{(XGB)}.$$

L'ensemble combina le tre previsioni tramite soft voting, ottenendo:

$$p_t^{(\text{ENS})} = \frac{p_t^{(LR)} + p_t^{(RF)} + p_t^{(XGB)}}{3},$$

e la decisione operativa è definita come:

$$\hat{y}_t = \begin{cases} 1 & \text{se } p_t^{(\text{ENS})} \geq 0.5, \\ 0 & \text{altrimenti.} \end{cases}$$

Anche l'ensemble è stimato in walk-forward expanding window, con ricalibrazione mensile, garantendo che ogni previsione sia realmente fuori campione.

Il backtest operativo comprende 2183 osservazioni out-of-sample. Le principali metriche ottenute sono:

- Accuratezza: 0.4796
- ROC-AUC: 0.4807

La matrice di confusione:

$$\begin{bmatrix} 411 & 650 \\ 486 & 636 \end{bmatrix}$$

evidenzia una moderata capacità di cogliere movimenti rialzisti (classe 1), mentre la classe ribassista risulta più difficile da identificare. Il classification report conferma questo comportamento, con:

- precision (0) = 0.4582, recall (0) = 0.3874
- precision (1) = 0.4946, recall (1) = 0.5668

Nel complesso, il modello mostra prestazioni inferiori al caso casuale, risultato coerente con i mercati altamente efficienti e rumorosi come Bitcoin a frequenza daily. In particolare, i rendimenti mostrano scarsa dipendenza lineare (sezione 4.1.0) e forte presenza di code pesanti, rendendo difficile per

algoritmi supervisionati apprendere pattern stabili nel tempo. Nonostante l'architettura ibrida fornisca una rappresentazione ricca della struttura dei dati, i risultati ottenuti confermano alcune proprietà note dei mercati crypto:

1) Bassa prevedibilità direzionale daily, anche in presenza di feature ibride ARIMA/ARFIMA.
2) Instabilità temporale dei pattern, che riduce l'efficacia dei modelli non lineari in walk-forward.
3) Elevata volatilità e code pesanti, che complicano l'apprendimento supervisionato.

4.2.2 ARIMA/ARFIMA + DL

In parallelo ai modelli ibridi basati su ensemble di algoritmi di apprendimento automatico, si è considerato l'impiego di Reti Neurali Ricorrenti della famiglia Long Short-Term Memory (LSTM) per modellare le dipendenze dinamiche della serie dei rendimenti logaritmici. Le architetture LSTM sono ampiamente utilizzate per la loro capacità di gestire dipendenze di lungo periodo e dinamiche non lineari. Sono stati considerati due modelli principali:

1) ARIMA + LSTM: il modello LSTM riceve in ingresso una sequenza di lunghezza fissa (20 giorni) costituita dai lag dei rendimenti logaritmici $(r_{t-1}, r_{t-2}, r_{t-3}, r_{t-5})$ e la previsione ARIMA a un passo avanti $\hat{r}_t^{(\mathrm{ARIMA})}$
2) ARFIMA + LSTM: analogo al precedente, ma la feature previsionale è la previsione della componente ARFIMA, $\hat{r}_t^{(\mathrm{ARFIMA})}$, ottenuta tramite differenziazione frazionaria e modello ARMA sulla serie così trasformata.

In entrambi i casi, la rete LSTM ha una struttura compatta, costituita da uno strato LSTM con 32 unità, uno strato di dropout al 20 %, impiegato per ridurre il rischio di overfitting, uno strato d'uscita denso con un'unità e funzione di attivazione sigmoide che restituisce la probabilità prevista di rendimento positivo nel giorno successivo.

La variabile di output è definita come variabile binaria:

$$y_t = \begin{cases} 1 & \text{se } r_{t+1} > 0, \\ 0 & \text{altrimenti,} \end{cases}$$

coerentemente con quanto adottato per i modelli di classificazione basati su ensemble. Per garantire un confronto metodologicamente corretto con i modelli ARIMA/ARFIMA + ensemble, anche i modelli LSTM sono stati addestrati in walk-forward expanding window. In particolare, si è adottato il seguente schema:

1) si costruiscono sequenze input-output di lunghezza 20, scorrendo la serie dei rendimenti e delle previsioni ARIMA/ARFIMA;
2) si utilizza un numero minimo di circa 365 sequenze per il primo addestramento del modello, così da disporre di un campione storico sufficiente;
3) ogni 30 nuove osservazioni si ricalibra completamente la rete LSTM sulla finestra espandente disponibile;
4) a ciascun passo, la previsione per il giorno successivo è interamente fuori campione, poiché il modello non ha accesso a informazioni future.

Durante la fase di addestramento, le feature vengono standardizzate sulla sola porzione di training, e si utilizza early stopping basato sulla validation loss per limitare il rischio di overfitting. L'intero processo è ripetuto in modo iterativo, così da produrre una sequenza di previsioni out-of-sample comparabile con quella generata dagli ensemble di algoritmi di classificazione. I risultati empirici mostrano che, nel contesto daily su Bitcoin, i modelli ibridi basati su LSTM non riescono a estrarre una struttura predittiva stabile dalla serie dei rendimenti. Per il modello ARIMA + LSTM, l'accuratezza complessiva è pari a circa 0.50, con una ROC-AUC prossima a 0.49. Il modello ARFIMA + LSTM presenta risultati analoghi, con un'accuratezza intorno a 0.50 e una ROC-AUC di poco inferiore a 0.50. La matrice di confusione evidenzia un comportamento sbilanciato, entrambi tendono a classificare con maggiore successo i giorni caratterizzati da rendimenti positivi (classe 1), mostrando invece una capacità limitata di identificare correttamente i giorni ribassisti (classe 0).

Questo pattern riflette la lieve asimmetria della serie, ma non si traduce in una capacità predittiva complessivamente superiore al caso casuale.

4.2.3 Confronto

La tabella di confronto tra i modelli (ARIMA/ARFIMA + ensemble ML, ARIMA + LSTM, ARFIMA + LSTM) mostra che:

- gli ensemble di modelli di apprendimento automatico, pur sfruttando congiuntamente le lag dei rendimenti e le previsioni ARIMA/ARFIMA, ottengono accuratezze inferiori a 0.50 e valori di ROC-AUC prossimi a 0.48;
- i modelli LSTM, nonostante la loro maggiore flessibilità e capacità teorica di modellare dipendenze non lineari di lungo periodo, non superano in modo significativo gli ensemble, mantenendo performance sostanzialmente allineate al benchmark casuale.

Nel complesso, si osserva che, sul mercato Bitcoin a frequenza giornaliera, né gli approcci lineari (ARIMA/ARFIMA), né gli ensemble di modelli di Machine Learning, né le reti LSTM sono in grado di sfruttare in modo robusto eventuali pattern predittivi nei rendimenti. I risultati dei modelli ibridi giornalieri sono sintetizzati in Figura 2, dalla quale emerge come nessuna delle architetture considerate riesca a superare in modo significativo il benchmark casuale. In particolare, sia gli ensemble di modelli di apprendimento automatico sia le reti LSTM presentano accuratezze prossime allo 0,50 e valori di ROC-AUC inferiori allo 0,50, indicando l'assenza di una struttura predittiva sfruttabile nella dinamica direzionale dei rendimenti logaritmici quotidiani di Bitcoin. Si osserva inoltre un marcato sbilanciamento del recall tra le due classi, con una maggiore capacità di individuazione dei giorni rialzisti rispetto a quelli ribassisti, fenomeno coerente con la lieve asimmetria osservata nella distribuzione dei rendimenti.

Modello	Accuracy	ROC-AUC	Recall Classe 0	Recall Classe 1
Ensemble ML	0.4796	0.4807	0.3874	0.5668
ARIMA + LSTM	0.4998	0.4861	0.137	0.8426
ARFIMA + LSTM	0.5002	0.4947	0.1941	0.7896

Figura 2 - La tabella riporta l'accuratezza, la ROC-AUC e il recall per ciascuna delle due classi (giorni con rendimento negativo e positivo) ottenuti da tre diverse famiglie di modelli: (i) un ensemble di algoritmi di apprendimento automatico basati su feature lagged e previsioni ARIMA/ARFIMA, (ii) un modello LSTM ibrido con componente ARIMA, e (iii) un modello LSTM ibrido con componente ARFIMA. I risultati sono calcolati in completa modalità out-of-sample mediante schema walk-forward expanding window.

4.2.4 Interpretabilità dei modelli ibridi mediante SHAP

L'interpretabilità dei modelli predittivi riveste un ruolo centrale, in quanto consente di comprendere quali variabili contribuiscano maggiormente alla generazione dei segnali operativi e con quale intensità tali contributi influenzino la probabilità di previsione della direzione dei rendimenti. A tal fine, per il modello ibrido ARIMA/ARFIMA + ensemble di algoritmi di apprendimento automatico è stato adottato il metodo SHapley Additive exPlanations (SHAP), basato su una decomposizione additiva delle previsioni del modello in contributi marginali associati a ogni feature. Data la struttura eterogenea dell'ensemble, composto da Regressione Logistica, Random Forest e XGBoost, l'analisi è stata condotta sul modello XGBoost, che rappresenta il componente non lineare dell'ensemble e risulta il più adatto all'applicazione del TreeExplainer SHAP. L'analisi è stata effettuata sull'intero insieme out-of-sample generato mediante schema walk-forward expanding window, assicurando la piena coerenza metodologica con i risultati presentati nelle sezioni precedenti. La Figura 3 mostra il *SHAP* summary plot, che evidenzia la distribuzione dei valori SHAP per ciascuna feature. È possibile osservare come i contributi siano generalmente simmetrici attorno allo zero, fenomeno coerente con la scarsa prevedibilità direzionale dei rendimenti giornalieri di Bitcoin. Il corrispondente grafico di

importanza globale (Figura 4) conferma che le feature più rilevanti per il modello sono (rispettivamente): ret_log_lag3; ret_log_lag2; ret_log_lag.
Mentre le previsioni econometriche arima_pred_tplus1 e arfima_pred_tplus1 mostrano un contributo significativamente inferiore. Questo risultato suggerisce che il modello si fonda quasi esclusivamente su informazioni autoregressive di brevissimo periodo, mentre le previsioni ARIMA e ARFIMA, pur concepite come feature predittive lineari, non riescono a fornire un contributo discriminativo significativo. I dependence plots riportati nelle Figure 5.a-5.c consentono di analizzare la relazione tra ciascuna delle tre feature principali e il corrispondente valore SHAP. In tutti i casi emerge un comportamento riconducibile a rumore, i valori SHAP variano attorno allo zero senza mostrare una struttura funzionale stabile o monotona. In particolare:

- valori estremi dei rendimenti passati (sia positivi sia negativi) generano SHAP sia positivi sia negativi, segnalando l'assenza di una relazione deterministica tra l'entità del movimento precedente e la previsione della direzione futura;
- non emergono zone a elevata densità associabili a pattern ripetuti o regimi di mercato persistenti;
- le interazioni tra lag (colorazione del grafico) appaiono deboli e non strutturate, coerentemente con l'ipotesi di dinamica approssimabile come processo di martingala.

Questi risultati convergono verso la stessa conclusione metodologica delle sezioni precedenti, nel mercato Bitcoin a frequenza giornaliera non sono presenti pattern stabili sfruttabili dai modelli predittivi, né lineari, né basati su alberi decisionali, né Deep Learning. I modelli tendono a oscillare attorno al comportamento casuale, e la struttura dei valori SHAP riflette perfettamente tale aleatorietà, mostrando contributi marginali vicini allo zero e distribuzioni simmetriche. In definitiva l'analisi SHAP conferma che:

- l'ensemble utilizza principalmente lag dei rendimenti, ma i contributi sono instabili e rumorosi;
- le previsioni ARIMA e ARFIMA, pur teoricamente informative, non apportano valore predittivo addizionale in ambito daily;
- nessuna feature mostra un impatto sistematicamente positivo o negativo sul segnale, suggerendo assenza di relazione causale robusta.

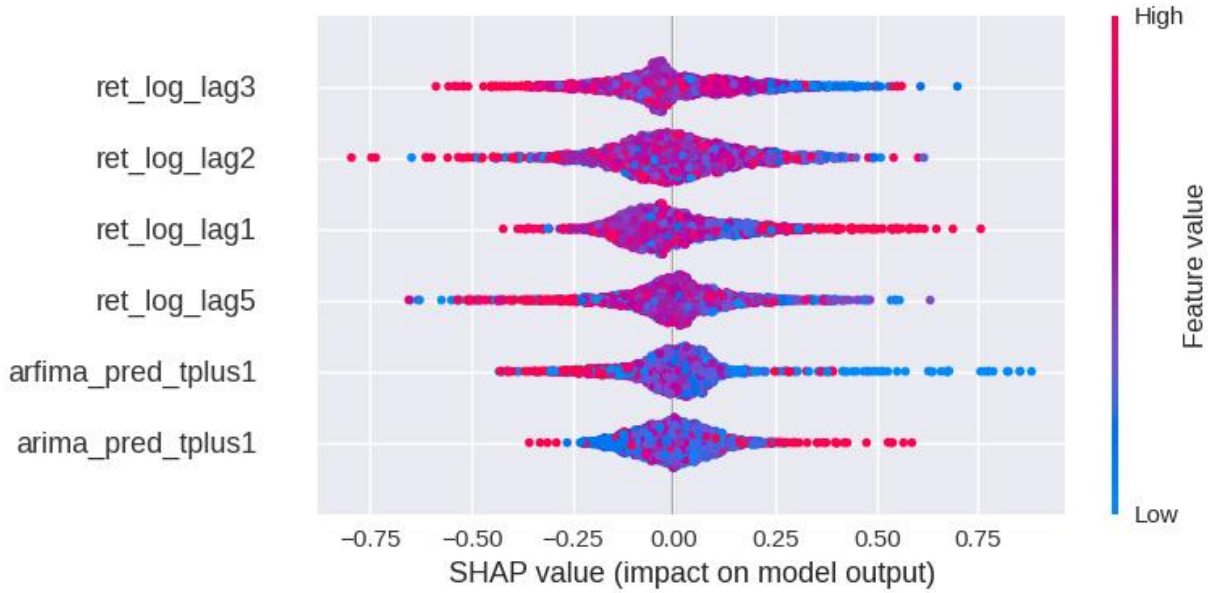

Figura 3 - SHAP summary plot del modello ensemble: raffigura la distribuzione dei valori SHAP per ciascuna feature, evidenziando l'impatto marginale delle variabili sul modello.

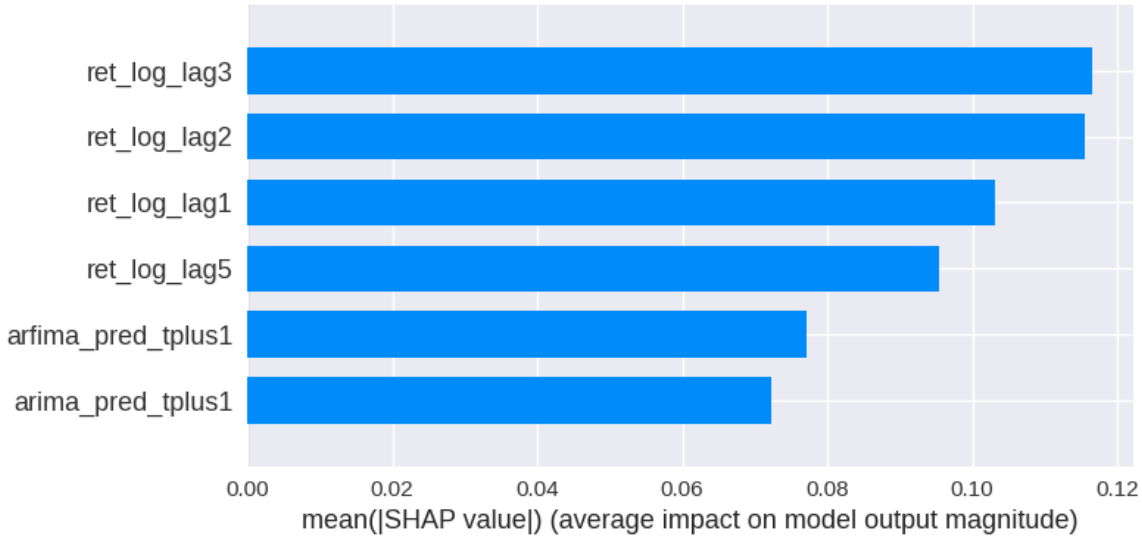

Figura 4 - Importanza media assoluta dei valori SHAP: le barre rappresentano il contributo globale di ogni feature alla previsione del modello.

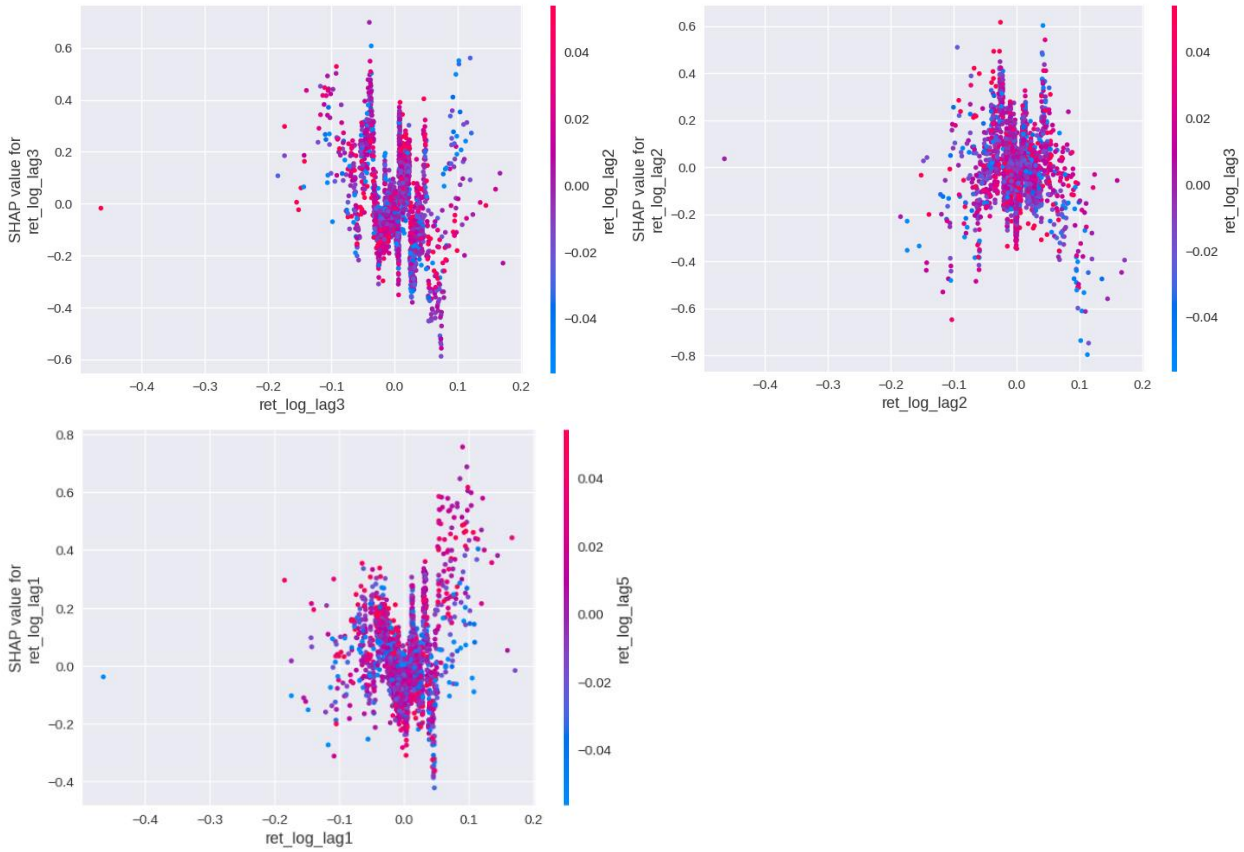

Figure 5.a-5.c - SHAP dependence plots per le tre feature più rilevanti: illustrano la relazione tra ciascuna feature e il valore SHAP corrispondente, evidenziando l'assenza di pattern predittivi sistematici.

4.3 Rischio e costi

4.3.1 Stima della volatilità condizionata e misure di rischio (GARCH)

La modellazione della volatilità riveste un ruolo fondamentale nella valutazione del rischio e nella definizione dei costi operativi delle strategie di trading. Come mostrato, i rendimenti logaritmici di Bitcoin presentano una forte eterogeneità della varianza nel tempo e una marcata presenza di code pesanti. In questo contesto, i modelli GARCH costituiscono uno strumento particolarmente adatto

per stimare la volatilità condizionata e ottenere misure di rischio coerenti con la dinamica empirica della serie. In questa sede si è stimato un modello GARCH (1,1) con innovazioni distribuite secondo una t-Student standardizzata. Il modello assume la forma:

$$r_t = \sigma_t z_t, z_t \sim t_\nu,$$
$$\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2,$$

dove $\omega > 0$, $\alpha \geq 0$ e $\beta \geq 0$ sono i parametri del processo, e ν rappresenta i gradi di libertà della distribuzione t-Student. La stima del modello sul campione 2017–2024 (2.920 osservazioni) produce i parametri riportati nella Tabella seguente.

- $\alpha_1 = 0.0878$, altamente significativo ($p < 10^{-7}$), indica la sensibilità della volatilità agli shock recenti;
- $\beta_1 = 0.9122$, anch'esso estremamente significativo, evidenzia un forte effetto di persistenza della volatilità;
- $\alpha_1 + \beta_1 = 0.99997$, valore molto prossimo all'unità, compatibile con processi IGARCH[18] e tipico dei mercati altamente volatili;
- $\nu = 3.2241$, parametro dei gradi di libertà, conferma la presenza di code molto pesanti, coerentemente con quanto osservato nelle statistiche di kurtosi.

La combinazione di elevata persistenza (β) e shock immediati moderati (α) rappresenta una caratteristica comune degli asset crypto, che presentano cluster di volatilità particolarmente estesi nel tempo. La Figura 6 riporta l'evoluzione della volatilità condizionata σ_t stimata tramite il modello GARCH. Sono evidenti:

- periodi di forte espansione della volatilità (ad esempio 2018, 2020 e 2022);
- fasi di contrazione successiva tipiche dei mercati ad alta intensità speculativa;
- un livello mediano di volatilità notevolmente elevato rispetto agli asset tradizionali.

La volatilità condizionata costituisce un elemento essenziale sia per valutare la rischiosità dell'asset, sia per determinare i costi operativi dinamici delle strategie di trading basate sui modelli predittivi analizzati nelle sezioni precedenti. A tal fine, si considera un modello in cui lo slippage operativo cresce in funzione della volatilità giornaliera, secondo una relazione del tipo:

$$\text{Cost}_t = c_0 + c_1 \sigma_t,$$

Utilizzando il modello GARCH stimato e la distribuzione t-Student standardizzata per gli shock, sono state calcolate tre misure di rischio fondamentali:

1) Value-at-Risk parametrico (VaR 95%)

$$\text{VaR}_{0.95}(t) = \sigma_t \cdot q_{t,\nu}(0.05),$$

dove $q_{t,\nu}$ è il quantile al 5% della t-Student a ν gradi di libertà. Il VaR fornisce una misura del peggior rendimento atteso in condizioni normali di mercato con livello di confidenza del 95%.

2) Expected Shortfall (ES)

$$\text{ES}_{0.95}(t) = E[r_t \mid r_t < \text{VaR}_{0.95}],$$

che valuta la perdita media condizionata all'evento estremo. L'ES è considerata una misura di rischio più coerente del VaR, in quanto subadditiva e sensibile alla coda della distribuzione.

[18] Un processo IGARCH (Integrated GARCH) è un modello di volatilità in cui lo shock alla varianza ha persistenza pari a 1, cioè gli effetti degli shock non si dissipano nel tempo e la volatilità segue un comportamento simile a una random walk.

3) Conditional Value-at-Risk (CVaR)
Coincide con l'ES nel caso di distribuzioni continue, quindi:

$$\mathrm{CVaR}_{0.95}(t) = \mathrm{ES}_{0.95}(t).$$

La Figura 7 mostra il confronto tra i rendimenti giornalieri e il VaR dinamico. Si osserva che molteplici violazioni del VaR si concentrano nei periodi di elevata volatilità, confermando l'importanza di una modellazione condizionata delle code di distribuzione. Le prime osservazioni del dataset arricchito sono mostrate nella Tabella seguente:

Data	**ret_log**	**sigma_t**	**VaR_95**	**ES_95**
2017-01-02	0.0232	0.0580	-0.1328	-0.2127
2017-01-03	0.0214	0.0560	-0.1282	-0.2053
2017-01-04	0.1010	0.0540	-0.1237	-0.1981

L'informazione contenuta nella volatilità condizionata σ_t e nelle misure di rischio VaR, ES e CVaR sarà utilizzata nelle sezioni successive per valutare la robustezza delle strategie basate sui modelli predittivi (es. soglia di segnale, gestione del rischio), quantificare i costi effettivi di esecuzione, definire metriche aggiustate per il rischio e confrontare in modo corretto le performance operative dei modelli. I risultati confermano che Bitcoin presenta una dinamica estremamente volatile e con code pesanti, elementi che rendono particolarmente difficile la previsione direzionale ma fondamentali per la gestione del rischio.

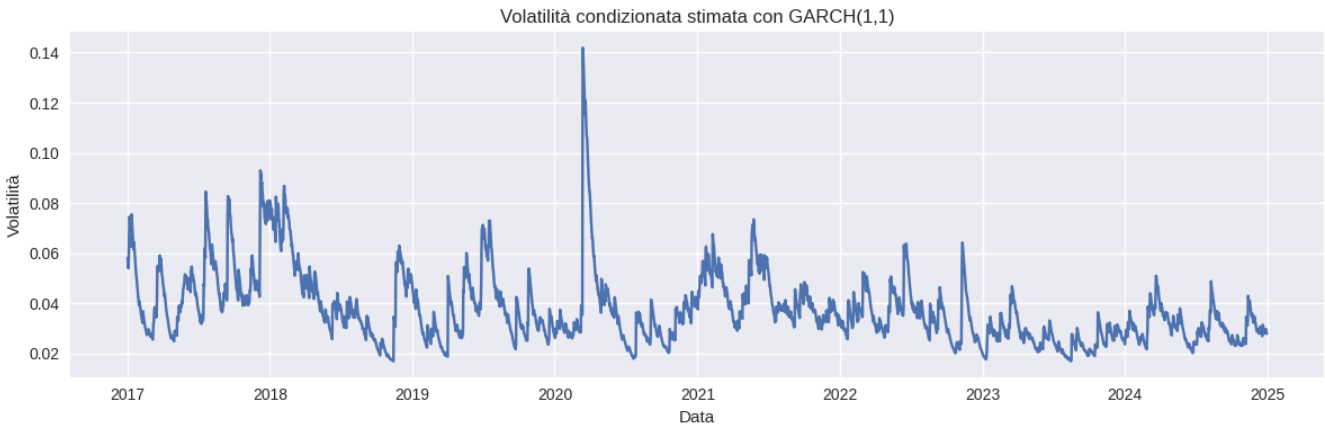

Figura 6 - Volatilità condizionata stimata tramite GARCH (1,1): Mostra l'evoluzione nel tempo della volatilità giornaliera stimata, evidenziando cluster e periodi di forte regime shift.

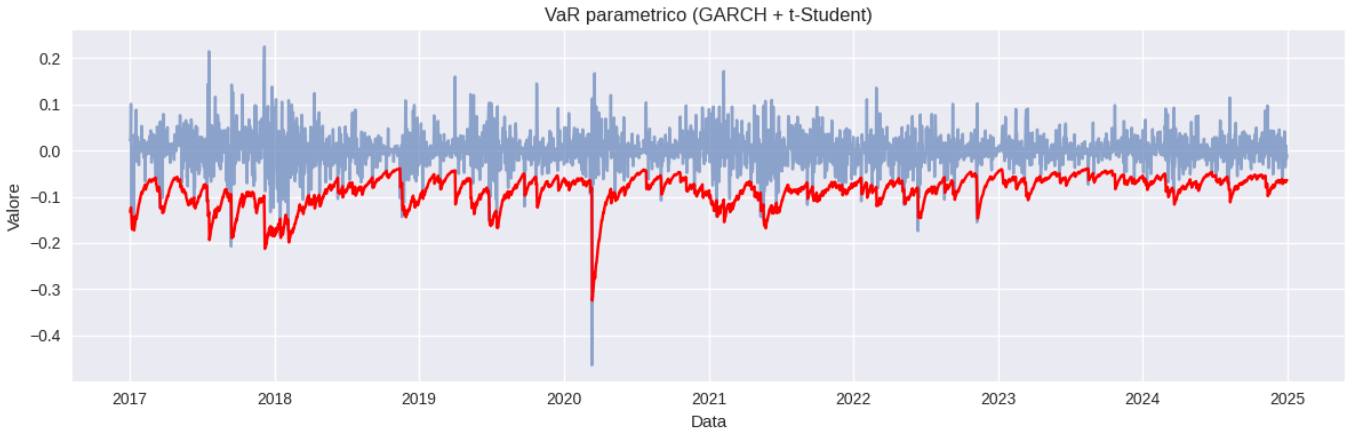

Figura 7 - Value-at-Risk (95%) dinamico su rendimenti giornalieri: confronto tra rendimenti effettivi e VaR parametrico ottenuto dal modello GARCH con innovazioni t-Student.

4.3.2 Metriche di rischio delle strategie operative

L'ultima fase dell'analisi giornaliera riguarda la valutazione delle performance risk-adjusted delle strategie. In particolare, per la strategia basata sull'ensemble di algoritmi di apprendimento automatico è stata costruita una serie di rendimenti operativi che incorpora sia i segnali previsivi sia una componente di costo dinamica, funzione della volatilità condizionata stimata con il modello GARCH (1,1). La regola di trading considerata è di tipo direzionale, ovvero per ogni giorno t il modello ensemble fornisce una previsione binaria $\hat{y}_t \in \{0,1\}$, dove 1 indica un rialzo atteso e 0 un ribasso. Tale previsione viene trasformata in un segnale di posizione $\text{signal}_t \in \{-1, +1\}$ secondo:

$$\text{signal}_t = 2\hat{y}_t - 1,$$

così che il portafoglio assuma una posizione long in caso di previsione rialzista e short in caso di previsione ribassista. Il rendimento operativo della strategia al tempo t è definito come:

$$r_t^{\text{strat}} = \text{signal}_t \cdot r_{t+1} - \text{Cost}_t,$$

dove r_{t+1} rappresenta il rendimento logaritmico del giorno successivo e Cost_t è un termine di costo che tiene conto di commissioni e slippage. Per modellare i costi in modo realistico e dipendente dalle condizioni di mercato, si è adottata una specificazione in cui i costi aumentano al crescere della volatilità condizionata giornaliera σ_t, secondo la relazione:

$$\text{Cost}_t = c_0 + c_1\sigma_t,$$

dove c_0 rappresenta una componente fissa (ad esempio, costi minimi di transazione) e $c_1$una componente proporzionale alla volatilità

A partire dalla serie $\{r_t^{\text{strat}}\}$, sono stati calcolati:

- il rendimento medio giornaliero e quello annualizzato, assumendo 252 giorni di trading all'anno (similmente ai giorni di trading azionario);
- la volatilità annualizzata dei rendimenti della strategia;
- lo Shape ratio[19], definito come:

$$\text{Sharpe} = \frac{\mu_{\text{ann}}}{\sigma_{\text{ann}}},$$

  dove μ_{ann} è il rendimento medio annualizzato e σ_{ann} la volatilità annualizzata;
- il Sortino ratio[20], che sostituisce al denominatore la deviazione standard delle sole osservazioni negative, concentrandosi sul rischio di downside:

$$\text{Sortino} = \frac{\mu_{\text{ann}}}{\sigma_{\text{down, ann}}},$$

- il Massimo Drawdown (MDD), definito come la massima perdita relativa dal picco al successivo minimo della curva dei capitali:

[19] lo Sharpe Ratio quanto rendimento ottieni oltre il tasso privo di rischio per ogni unità di volatilità assunta, aiutandoti a capire se il rischio che prendi è 'ben pagato'.

[20] Il Sortino Ratio misura quanto rendimento ottieni per ogni unità di rischio negativo (solo le perdite), ignorando la volatilità favorevole.

$$\text{MDD} = \max_{t}\left(1 - \frac{P_t}{\max\limits_{s \le t} P_s}\right),$$

- il Calmar ratio, che confronta il rendimento annualizzato con il massimo drawdown (in valore assoluto):

$$\text{Calmar} = \frac{\mu_{\text{ann}}}{|\ \text{MDD}\ |},$$

- il Conditional Value-at-Risk (CVaR) empirico al 95%, calcolato come media delle perdite al di sotto del percentile al 5% della distribuzione dei rendimenti della strategia.

I risultati ottenuti per la strategia basata sull'ensemble ML giornaliero evidenziano una chiara criticità. Il rendimento medio giornaliero risulta negativo, pari a circa -0.0055, che si traduce in un rendimento medio annualizzato di circa -1.40. A fronte di una volatilità annualizzata pari a circa 0.54, lo Sharpe ratio risulta fortemente negativo (circa -2.56), indicando una combinazione sfavorevole di rischio e rendimento. Anche il Sortino ratio è negativo e di entità comparabile (circa -3.12), segnalando che, al netto dei soli episodi di perdita, la strategia non offre alcun compenso per il rischio assunto. Il Massimo Drawdown risulta prossimo al -100%, indicando che, nel corso del backtest, la curva dei capitali della strategia subisce, in almeno un'occasione, una perdita cumulata tale da azzerare di fatto il capitale iniziale. Di conseguenza, il rapporto di Calmar è anch'esso fortemente negativo (circa -1.40), coerentemente con un profilo di rischio-rendimento non accettabile per un investitore razionale. Dal punto di vista del rischio di coda, il VaR empirico al 95% e il corrispondente CVaR empirico evidenziano perdite giornaliere estreme di ordine rilevante. In particolare, il CVaR al 95% è intorno a -0.093, indicando che, nelle peggiori giornate che compongono il 5% di coda, la perdita media giornaliera della strategia è prossima al 9% in termini di rendimento logaritmico. Tale entità, unita all'osservazione di un drawdown massimo vicino al -100%, conferma che la strategia non solo non è profittevole, ma presenta anche un profilo di rischio estremamente sfavorevole. Le metriche di rischio ottenute per la strategia basata sull'ensemble ML giornaliero suggeriscono che:

- il potere predittivo marginale dei modelli è insufficiente a compensare sia la volatilità intrinseca dell'asset sia i costi di transazione, soprattutto quando questi ultimi sono modellati in modo realistico e dipendente dalla volatilità condizionata;
- l'adozione di strategie direzionali su Bitcoin a frequenza giornaliera, basate esclusivamente su modelli di previsione dei rendimenti, conduce nel campione analizzato a performance fortemente negative e a livelli di rischio non gestibili;
- l'analisi conferma la necessità di spostare il focus verso orizzonti temporali diversi (ad esempio intraday) o verso strategie di natura diversa (ad esempio market-neutral, carry, volatilità)

Visualizzazioni grafiche della strategia sono mostrate nelle Figure 8-9, in particolare:

- La Figura 8 riporta la curva dei capitali della strategia ensemble ML, ottenuta investendo un capitale iniziale normalizzato a 1 e reinvestendo sistematicamente i rendimenti giornalieri della strategia nel periodo di analisi. La curva mostra un progressivo deterioramento del valore del portafoglio, con fasi di perdita particolarmente marcate, in linea con i valori negativi di Sharpe e Sortino e con il massimo drawdown molto elevato.
- La Figura 9 mostra invece l'andamento del drawdown nel tempo. Si osservano lunghi periodi in cui la strategia rimane al di sotto dei massimi storici precedenti, senza recuperare in modo stabile, fenomeno che corrobora l'interpretazione secondo cui la combinazione di debole potere predittivo e costi di transazione dinamici annulla qualsiasi potenziale profitto atteso.

Figura 8 - Curva dei capitali della strategia Ensemble ML: Andamento del valore cumulato del portafoglio (base 1) associato alla strategia basata sull'ensemble di modelli predittivi giornalieri, comprensiva dei costi di transazione dinamici.

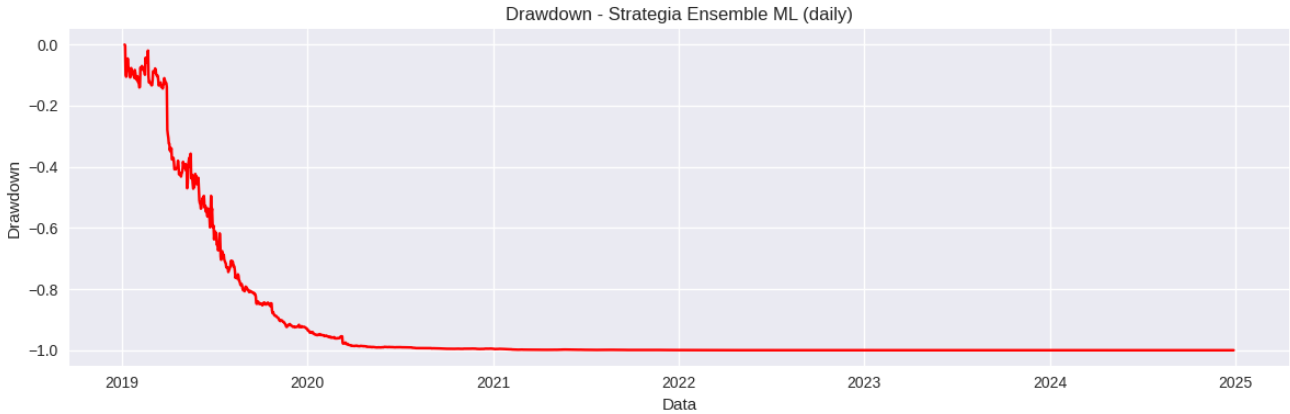

Figura 9 - Drawdown della strategia Ensemble ML: Evoluzione temporale del drawdown relativo (distanza percentuale dal massimo cumulato) per la strategia basata sull'ensemble ML, che evidenzia fasi prolungate di perdita e un drawdown massimo prossimo al -100%.

5 Conclusioni

5.1 Sintesi dei risultati

La presente tesi ha analizzato la capacità predittiva e operativa di modelli quantitativi applicati ai rendimenti giornalieri di Bitcoin, con particolare attenzione a strutture ibride che combinano modelli econometrici lineari (ARIMA, ARFIMA) con algoritmi di Machine Learning e architetture di Deep Learning. L'intero framework sperimentale è stato costruito secondo un'impostazione rigorosamente time-consistent, basata su validazione walk-forward expanding window e su metriche calcolate esclusivamente out-of-sample, al fine di garantire risultati metodologicamente robusti e privi di bias informativi. I risultati empirici mostrano in modo chiaro come, nel contesto giornaliero di Bitcoin, la prevedibilità direzionale dei rendimenti sia estremamente limitata. Nessuna delle architetture considerate, né i modelli econometrici lineari, né gli ensemble di algoritmi di Machine Learning, né le reti LSTM, è riuscita a superare in modo significativo il benchmark casuale. Le accuratezze si collocano stabilmente intorno allo 0,50, mentre i valori di ROC-AUC risultano inferiori o prossimi a 0,50, indicando l'assenza di una struttura discriminativa sfruttabile. In particolare, l'integrazione delle previsioni ARIMA e ARFIMA come feature additive nei modelli non lineari non ha prodotto un miglioramento sostanziale delle performance. L'analisi di interpretabilità tramite SHAP ha confermato che il contributo informativo delle previsioni econometriche è marginale, mentre il modello ensemble tende a basarsi quasi esclusivamente sui lag dei rendimenti, che tuttavia presentano contributi instabili e privi di una relazione strutturata con la variabile target. Anche le architetture LSTM, pur teoricamente più flessibili e capaci di modellare dipendenze temporali non lineari, non hanno mostrato un vantaggio competitivo rispetto agli ensemble di Machine Learning, confermando la difficoltà di estrarre pattern stabili dai rendimenti giornalieri di Bitcoin. Dal punto di vista operativo, la costruzione di una strategia direzionale long/short basata sulle previsioni dell'ensemble ML ha evidenziato risultati fortemente negativi. Una volta incorporati costi di transazione dinamici, modellati come funzione crescente della volatilità condizionata stimata tramite GARCH (1,1), la strategia presenta rendimenti medi negativi, Sharpe e Sortino ratio ampiamente inferiori a zero e un massimo drawdown prossimo al −100%. Tali evidenze indicano che il debole potere predittivo dei modelli non è sufficiente a compensare l'elevata volatilità dell'asset e le frizioni di mercato realistiche. Nel complesso, i risultati empirici convergono verso una conclusione chiara, ovvero nel periodo analizzato e a frequenza giornaliera, il mercato di Bitcoin mostra un comportamento compatibile con un processo altamente rumoroso e prossimo a una martingala, rendendo inefficaci le strategie direzionali basate esclusivamente sulla previsione del segno dei rendimenti.

5.2 Contributi della tesi e considerazioni finali

Nonostante i risultati negativi in termini di performance predittiva e operativa, il contributo della tesi è rilevante sotto diversi profili. In primo luogo, il lavoro fornisce una valutazione empirica rigorosa di modelli ibridi Econometrici–ML–DL applicati al mercato crypto, utilizzando un framework metodologico allineato alle migliori pratiche della letteratura recente. L'adozione sistematica della validazione walk-forward, l'assenza di feature ingegnerizzate complesse e l'uso esclusivo di metriche out-of-sample rafforzano l'affidabilità dei risultati. In secondo luogo, la tesi contribuisce al dibattito sulla limitata trasferibilità operativa dei modelli predittivi nel trading quantitativo. I risultati mostrano come buone proprietà statistiche o lievi segnali predittivi non si traducano necessariamente in strategie profittevoli, soprattutto quando si considerano in modo realistico volatilità, costi di transazione e rischio di coda. Infine, l'analisi di interpretabilità tramite SHAP offre una evidenza diretta della natura rumorosa delle relazioni apprese dai modelli, confermando che l'assenza di performance non è dovuta a scelte implementative specifiche, ma riflette proprietà strutturali del mercato analizzato. Il presente lavoro presenta alcuni limiti che è opportuno evidenziare. In primo luogo, l'analisi è stata condotta esclusivamente su dati giornalieri e su un singolo asset (Bitcoin). Sebbene ciò consenta un'analisi approfondita e coerente, limita la generalizzabilità dei risultati ad

altri mercati o frequenze temporali. In secondo luogo, la scelta di una feature engineering minimale, se da un lato riduce il rischio di overfitting e aumenta l'interpretabilità, dall'altro potrebbe escludere variabili informative rilevanti in contesti differenti. Infine, l'analisi si è concentrata su strategie direzionali pure. Altre classi di strategie, basate ad esempio sulla volatilità, su approcci market-neutral o su segnali cross-asset, non sono state considerate e potrebbero mostrare comportamenti differenti. Alla luce dei risultati ottenuti, emergono diversi possibili sviluppi futuri. Un primo filone riguarda l'estensione dell'analisi a frequenze temporali diverse, in particolare intraday, dove la microstruttura del mercato e la maggiore disponibilità informativa potrebbero rendere più efficace l'impiego di modelli non lineari. Un secondo sviluppo concerne l'esplorazione di strategie alternative alla previsione direzionale, come strategie market-neutral, di volatilità o basate su regime-switching, che potrebbero risultare più adatte a mercati caratterizzati da elevata incertezza e code pesanti. Ulteriori approfondimenti potrebbero includere l'integrazione di informazioni cross-asset, indicatori di liquidità o misure di order flow, nonché l'adozione di modelli bayesiani o di apprendimento rinforzato, che permettano una gestione dinamica del rischio e della posizione. Per concludere, la tesi mostra come, nonostante l'impiego di modelli sofisticati e architetture ibride, la previsione direzionale dei rendimenti giornalieri di Bitcoin rimanga un problema estremamente complesso e, nel campione analizzato, sostanzialmente non risolvibile. Questo risultato, lungi dall'essere un fallimento, rappresenta un'evidenza empirica importante, coerente con la letteratura più recente sul trading quantitativo e sull'efficienza dei mercati ad alta volatilità. Il lavoro conferma che la vera sfida nel trading quantitativo non risiede tanto nella complessità del modello, quanto nella comprensione dei limiti strutturali dei dati e nella costruzione di framework di valutazione realistici. In questo senso, il lavoro contribuisce ad una visione più matura e critica dell'uso dei modelli predittivi nei mercati finanziari, sottolineando l'importanza di un approccio rigoroso, trasparente e consapevole dei rischi.

Bibliografia

[1] Michael Halls Moore, Successful algorithmic trading, 2015

[2] Michael Halls Moore, Advanced algorithmic trading, 2017

[3] Krauss et al., Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the S&P 500, 2017

[4] Saifan et al., Investigating Algorithmic Stock Market Trading Using Ensemble Machine Learning Methods, 2020

[5] Dominik Stempien and Robert Slepaczuk, Hybrid Models for Financial Forecasting: Combining Econometric, Machine Learning, and Deep Learning Models, 2025